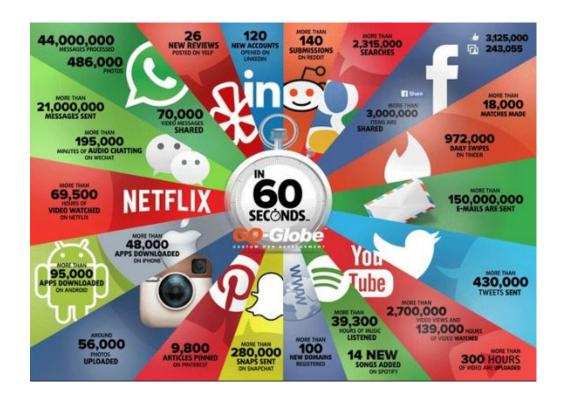
Klíčové aspekty budování a správy webových archivů a Webarchiv NK ČR

Obsah prezentace

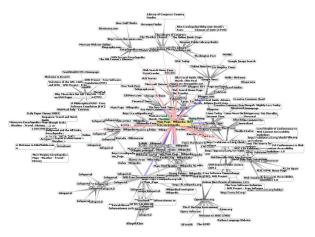
- specifika webového obsahu
- archivace webu a webové archivy
- klíčové aspekty:
 sklízení, nástroje, uživatelé, collection policy, legislativa
- příklady ze zahraničí Internet Archive, IIPC, RESAW
- Webarchiv NK ČR



Web je jedinečný a dynamický zdroj s velkou hodnotou pro současné i budoucí vědce. (IIPC)

Webový obsah

- proměnlivost, rychlé změny
- propojení obsahu odkazy
- obrovské množství obsahu a formátů
- absence závazných standardů



graphic representation of a minute fraction of the www, demonstrating hyperlinks

- nositel kulturní dědictví (národní knihovny)
- soubor velkých datových setů, nad kterými je možné vytvářet analýzy a využít je pro výzkum (knihovníci, archiváři, informační pracovníci, profesionálové v oblasti digital humanities, datoví vědci, vývojáři)



Information on the web changes regularly



A typical web page can be expected to last ~92 days before changing, moving, or going offline.

404 Not Found

nginx/1.10.3



Tento web není dostupný

Webové stránky na adrese http://malegranty.cz/ jsou možná dočasně nedostupné nebo mohly být přemístěny na novou webovou adresu.

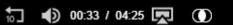
Vyhledejte na Googlu malegranty cz

ERR_NAME_RESOLUTION_FAILED

Načíst znovu

















Webové archivy

- Co archivovat / Jak budovat webový obsah? (collection policy)
- Kdo jsou uživatelé webových archivů?
- Legislativa?
- Infrastruktura?



Webová archivace

"Web archiving is the process of collecting portions of the World Wide Web, preserving the collections in an archival format, and then serving the archives for access and use." (IIPC)

- výběr webového obsahu
- sběr webového obsahu
- uchování sbírek v archivním formátu
- zpřístupnění
- uchování informací pro budoucí vědce, historiky a veřejnost

Co stojí za to archivovat?

"more is more, less is less"

VS.

"hoarding is not strategy"

Sklizení webového obsahu

celoplošné sklízení (kvantita)

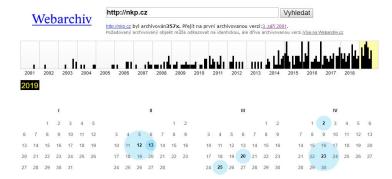
- všechno (Internet Archive)
- definovaná část webu (např. národní doména národní archivy, dohoda s poskytovateli národních domén)

výběrové sklízení (kvalita)

- kritéria (téma, instituce, typ dokumentů, ad.)
- kvalita (obsahová, technická)

Software

- Heritrix
- OpenWayback



 kontejnerové formáty WARC (standardizovaný, ISO norma) / ARC (starší, nestandardizovaný)

Uživatelé

- koncoví uživatelé, kteří by měli být schopni porozumět konkrétní množině informací (designated community, OAIS)
- definování uživatelů určuje podobu archivu (např. národní x univerzitní archiv)
- individuální, institucionální, výzkumníci a vědci

Collection policy

- akviziční pravidla pro budování archivu (sklizně celoplošné, výběrové, tematické)
- pravidla pro zpřístupňování a mazání obsahu (blacklisty x whitelisty)
- technická nastavení crawlerů
- vliv na autenticitu a provenienci dat

Legislativa

- různé přístupy pro archivaci, zpřístupňování i poskytování dat pro vědecké účely americká x evropská legislativa - smlouvy / otevřené licence, volně dostupná malá část archivu
- povinný výtisk elektronických dokumentů
- robots.txt (Internet Archive x Webarchiv) protokol pro zakázání přístupu robotům
- poskytování metadat

Internet Archive

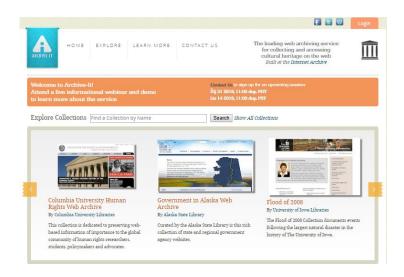
- digitální knihovna webových zdrojů a dalších digitálních objektů (knihy, videa, obrázky, software, audionahrávky, počítačové hry apod.)
- Brewster Kahle, https://archive.org
- volný přístup ke všem znalostem
- archivace webu od roku 1996
- open source nástroje (Heritrix, OpenWayback)



Archive-It

- https://archive-it.org
- více než 400 partnerských organizací v 16 zemích (univerzitní knihovny, státní archivy, nevláda

(univerzitní knihovny, státní archivy, nevládní organizace, muzea a knihovny umění, města...)



 aplikace, která umožňuje uchovávat webový obsah, vytvářet kolekce uložené v datových centrech Internet Archive

IIPC - International Internet Preservation Consortium http://netpreserve.org



platforma pro výzkum a vývoj v oblasti archivace webu, 57 členů

IIPC - International Internet Preservation Consortium

pracovní skupiny a projekty:

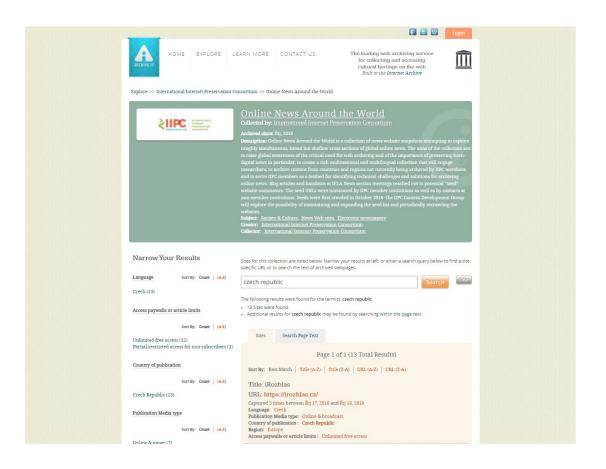
Content development working group

Preservation working group

Research working group

Training working group

- nástroje a software open source
- legislativa



Collaborative Collection – Online News Around the World

Topics and Themes

Explore over 100 collections of websites brought together by librarians, curators and other experts in response to a wide range of events and diverse topics and thirmes.



19th Century English Literature Resources relating to 19th century English literature and...



This collection looks at aging issues from a number of co...



Black and Asian Britain
Collection focusing on Black and Asian communities and c...



The UK Blogosphere (connected community of Web logs) has ...



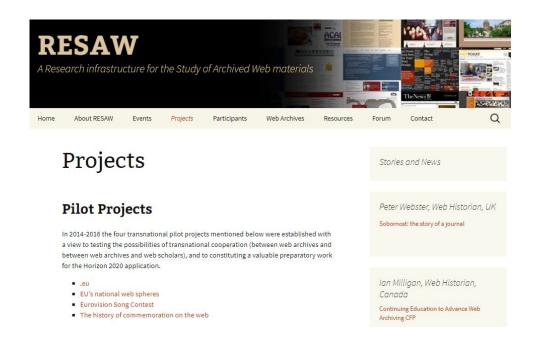






exit British Countryside British Dverseas Territories British Stand-up Comedy Archive

RESAW - A Research infrastructure for the Study of Archived Web materials



webové archivy: Netarkivet
(Dánsko), Bibliothèque nationale
de France – Archives de l'Internet
(Francie), Institut National de
l'Audiovisuel (Francie), Webarchief
van Nederland, Koninklijke
Bibliotheek (Nizozemí), The UK
Web Archive, the British Library
(Anglie), Arquivo.pt (Porugalsko),
Internet Memory Web archive

https://resaw.eu/

evropská výzkumná infrastruktura pro studium archivovaného webového obsahu

Výzvy

- zpřístupnění dat veřejnosti (legislativní omezení)
- collection policy profilování sbírek
- dynamický obsah, sociální média
- nástroje pro práci s archivními daty, velkými daty (big data) a metadaty
- spolupráce s vědci

Webarchiv

<u>Český webový archiv Národní knihovny České republiky</u>

Jsme Webarchiv

digitální knihovna, která uchovává weby pro budoucí generace.

Pokud je nebudeme průběžně archivovat, zmizí významná součást národního kulturního dědictví.



Historie

- 2000 projekt NK ČR, MZK a Masarykova Univerzita
- 2001 první archivovaná strana
- 2005 pravidelné sklízení obsahu
- 2007 členství IIPC International Internet Preservation Consortium

Webarchiv

http://www.cuni.cz/ Jít SRPEN ZÁŘÍ DUBEN » Zavřit X 269 archivovaných Nápověda ? verzí

Vyhledávání



Univerzita Karlova v Praze

Základní informace

Fakulty a další součásti

Studium

Věda a granty

Zahraniční styky

Informační služby

Co je nového

Staré stránky naleznete zde

Základní informace

- · Kontakt
 - · Adresa: Ovocný trh 5, Praha 1, 116 36, Czech Republic
 - · Telefon: +420 2 24491111
 - Fax: +420 2 24210695
 - · E-mail: UK@cuni.cz
- Základní dokumenty
 - Zakládací listina

 - Historie
 - · Statut a další vnitřní předpisy
- Orgány UK
 - Rektor
 - · Akademický senát
 - Vědecká rada

 - Správní rada
 - Kvestor
 - · Poradní orgány rektora
 - · Kolegium rektora, prorektoři
 - · Grantová rada
 - Ediční rada
 - Historická komise
- · Rektorát
- Struktura a seznam osob
- Úřední deska
- · Carolinum Spolek absolventů a přátel Univerzity Karlovy





CZECH LIBRARIES IN FLOODS



? Ask your library

About the National Library || Professional Activities || Publishing Activities || What's News? ||
Slavonic Library || Info || Services || Collections ||
Catalogues and Databases || Reference Centre
Library and Publisher's Matters

Czech version

Aktuálně

- 385 TB archivovaných dat
- 9,5 miliardy unikátních digitálních objektů (textové, obrazové, zvukové i video objekty, software, skripty, atd.)

Jak archivujeme?

Provádíme kompletní archivaci "celého" českého webu.

Souběžně probíhá <u>výběrová</u> a tematická archivace.

W

W

W

W

X

W

Bohužel!

Ne všechna data jsou dostupná online.

Může za to současná podoba autorského zákona, která byla vymyšlena pro knihy. Pro přístup k celému archivu musíte prozatím až k <u>nám</u>.



Legislativa

- Autorský zákon 121/2000 Sb., Knihovní licence § 37 rozmnoženina díla,
 archivační a konzervační potřeby
- volný přístup smlouva nebo Creative Commons
- povinný výtisk nezahrnuje digitální dokumenty

Software

- sklízení: Heritrix 3.4
- zpřístupnění: Open Wayback 2.3.1
- kurátoři: Seeder (software pro správu elektronických zdrojů, webových stránek a sklizní, https://github.com/webarchivcz/)
- katalogizace: WA-KAT (https://kat.webarchiv.cz/)

Hlavní stránka Hledání Zdroje Sklizně Vydavatelé Smlouvy Blacklisty Kontrola kvality Tematické kolekce Aktuality Historie hledání Github Nahlásit chybu Dokumentace Generovat whitelist Harvests urls

Seeder

Hlavní stránka

Zdroje ke katalogizaci	54	Hodnocení, která spravujete	48
Acta academica karviensia		Sokol : Česká obec sokolská	0
Ararauna.cz : O papoušcích, jej chovu a legislativě	jich	OLYMP : centrum sportu Ministerstv vnitra	/a
Art has no history		Tiskárna Ministerstva vnitra	0
Atelierforart.cz		Hodonín nostalgický	0
Biologické centrum Akademie v	rěd .	Obscura	0
České republiky, v. v. i.		Garanční systém finančního trhu	0
Bioprospect		Agentura pro podnikání a inovace (0
British Council Česká republika Ceny Trilobit		Podružná obrazová stránka hradu Hauenstein	0
česká asociace organizátorů veřejné lopravy		Houpací osel : káva a publicistika (0
Česká parazitologická společno	ost :	West Bohemian Historical Review (0
ČPS		Otevřená hodnocení	33
Zdroje, které potřebují technick dohled	ý 6	Aussiger Beiträge : Germanistische Schriftenreihe aus Forschung und Lehre	0
Headliner		Long	
Historie - Otázky - Problémy		Rating webových zpravodajských médií	0

48	Zdroje, které spravujete	45
0	adamquick.com	
terstva	Africké fialky: internetová přín jejich pěstování, množení a ty	
0	Agentura pro podnikání a inov	race
0	Bytová správa Ministerstva vr	nitra
0	CryptoSvět	
u ()	Česká asociace pro aktivity a ve výškách, z.s. : CRAA	práce
ce 🛈	Dokoupil.estranky.cz	
du	Etern	
ka 🚺	Ethnoentomology	
ew 🛈	Folk time	
33	Smlouvy v jednání	8
sche nd	Peak.cz : peníze, ekonomíka, komentáře	analýzy,
	Agosto Foundation	
ch (I)	Český lid	



Peak.cz : peníze, ekonomika, analýzy,

komentáře

Agosto Foundation



Collection policy

- Celoplošné sklizně
- Výběrové sklizně
- Tematické kolekce

```
<div class="date">
                   <div class="position">
                     <div class="hidden">2</div>
                      <div class="measure opacity20" id="Bre-25-2019"><img width="100%" height="100%"/>
              <div class="date"></div>
              <div class="date"></div>
             <div class="date"></div>
             <div class="date"></div>
             <div class="date"></div>
670
              >
                <div class="date"></div>
             </div>
     <div class="month" id="2019-3">
        <thead>
                <span class="label"></span>
          </thead>
          689 <div class="date"></div>
                <div class="date"></div>
             <div class="date">
                   <div class="position">
                     <div class="hidden">2</div>
                     <div class="measure opacity20" id="Dub-2-2019"><img width="100%" height="100%"/>
```

Celoplošné sklizně

- smlouva s poskytovatelem domény CZ.NIC
- jednou nebo dvakrát do roka sklizeň domény .cz
- dostupné pouze v knihovně
- 1,4 million domén
- stahování maximálně 5000 souborů z jedné domény

Tuto stránku Webarchiv nemůže zobrazit

Z důvodu autorského zákona nemůžeme tuto stránku zpřístupnění navštivte naše často kladené dotazy,

Výběrové sklizně

- selektivní, kurátorský přístup
 - bohemikální charakter (území, autorství, jazyk, předmět /obsah), nejen na české doméně
 - zdroje s historickou, vědeckou, kulturní nebo jinou informační hodnotou
- online přístup smlouva nebo licence Creative Commons
 - více než 5000 zdrojů
- pravidelné sklízení
- stahování maximálně 15 000 souborů z jedné domény

Webarchiv podle oborů

Přehled nasmlouvaných webů dle oborového třídění:

```
Vše 5172 / Antropologie, etnografie 164 / Beletrie 29 / Biologické vědy 225 / Divadlo, film, tanec 167 /
Ekonomické vědy, obchod 315 / Filozofie a náboženství 238 / Fyzika a příbuzné vědy 88 /
Geografie. Geologie. Vědy o Zemí 409 / Historie a pomocné historické vědy. Biografické studie 294 /
Hudba 156 / Chemie, Krystalografie, Mineralogické vědy 49 / Jazyk, lingvistika, literární věda 213
Knihovnictví, informatika, všeobecné, referenční literatura 294 / Lékařství 284 / Literatura pro děti a mládež 1 /
Matematika 45 / Politické vědy (Politologie, politika, veřejná správa, vojenství) 341 / Právo 147 /
Psychologie 83 / Sociologie 315 / Technika, technologie, inženýrství 281 /
Tělesná výchova a sport. Rekreace 213 / Umění, architektura 349 / Výchova a vzdělávání 222 /
Výpočetní technika 147 / Zemědělství 176
```

Umění, architektura /

```
Vše 349 / Architektura 55 / Fotografie 45 / Grafické umění, Grafika 11 / Kresba, Umělecká řemesla 15 /
Malířství 13 / Sochařství, keramika, porcelán, umělecké zpracování kovů 17 / Umění 72 /
Územní plánování. Urbanismus. Památková péče 21 / Výtvarné umění 98
```

Zobrazení: vizuální, textové



abcd : art brut



Action galleries



Adolf Wölfli : styořitel universa



Akademie výtvarných umění v Praze



Alice Nikitinová



Alšova jihočeská galerie v Hluboké nad Vltavou :



Amatérská obrazárna



Archeologické oddělení NPU Praha

Kurátoři

- výběr a hodnocení zdrojů
- uzavírání smluv s vydavateli
- katalogizace (RDA, metoda Konspektu)
- kontrola kvality

Nechte se Webarchivovat!

Mohu jednat za Zdroj s licenci uvedené zdroje Creative Commons
//

Tematické kolekce

aktuální události – sklízeny zpravidla před, během a po události

- plánované: volby, výročí
- nečekané: povodně, teroristické útoky

dlouhodobě budované kolekce – sklízeny průběžně

• Creative Commons, Periodické publikace, Univerzita Karlova

spolupráce s IIPC (Olympijské a paralympijské hry, Klimatická změna, Umělá inteligence)



CZ EN

Webarchiv uchovává český web

Pro první seznámení s webarchivem pokračujte zde

Tematické sbírky

Zobrazení: vizuální, <u>textové</u>

Tematické sbírky jsou monotematické soubory webových dokumentů. V rámci tematických sklizní sledujeme především takové děje, které doprovází celospolečenská debata a je u nich tedy předpoklad, že zaujmou významnější místo z hlediska dějin České republiky. Cílené vybíráme události, které mají širší ohlas v prostředí internetu. Monitorujeme očekávané akce (např. volby), ale i nenadálé situace (např. povodně).



Národní archiv veřejnoprávní původci

Národní archiv ze zákona vykonává dohled nad vyřazováním dokumentů a kontrolu spisové služby u řady orgánů a organizaci. Tematická kolekce zahrnuje webové stránky veřejnoprávních původců, o jejichž tzv. předarchivní pěči ...



Klimatická změna

Změna klimatu je jednou z největších výzev současnosti. Hledání řešení na vědecké i politické úrovní doprovází intenzivní celospolečenská debata. Kolekce, která vznikla ve spolupráci s mezinárodním konsorciem webových archivů IIPC. ...



Volby do Evropského parlamentu 2019

Ve dnech 24. a 25. 5. volí Česká republika své zástupce do Evropského parlamentu. Tematická kolekce zahrnuje weby politických stran, lidrů jednotlivých stran i ohlasy politických kampaní a výsledků voleb ...



Povodně 2013

V roce 2013 zasáhla velkou část České republiky povodeň. Vodní hladiny na mnoha místech dosáhly úrovně 20 i 50leté povodně. V tematické sklizni jsme se pokusili zachytit ohlasy na interneou....



Praha olympijská

Pražská radnice se na základě usnesení z 22. 3. 2007 rozhodla ucházet o pořadatelství Olympijských her v roce 2016. Informace o tomto rozhodnutí, jeho ohlas v masmědiích i na specializovaných ...



Karel IV. - 700. výročí narození

U příležitosti oslav 700. let od narození Karla IV. jsme připravili výběrovou sklizeň URL stránek zdrojů, které se aktuálně vztahují k výročí tohoto panovníka z různých perspektív. Vedle tematických projektů...



Nová budova Národní technické knihovny

V roce 2006 były započaty na Flemingově náměstí v blízkosti ČVUT a VŠCHT v Dejvicích stavební práce na stavbě nové budovy Národní technické knihovny. Přestože tomuto projektu nebylo ze strany ...



Václav Havel

Tematická sklizeň k úmrtí prvního polistopadového československého a českého prezidenta Václava Havla, který zemřel 18. prosince 2011, proběhla v několika kolech na přelomu roku 2011/2012. Do sklizně bylo zařazeno téměř ...



Volby do Evropského parlamentu 2014

Volby do Evropského parlamentu v květnu 2014 byly poznamenány zejména nízkou účastí českých voličů. Tematický sklizeň mapuje předvolební kampaně politických stran a jejich lídrů i volební výsledky a reakce na ...

Spolupráce s vědci a institucemi

metodologická podpora

Národní archiv, AV ČR, Úřad pro dohled nad hospodařením politických stran a politických hnutí

tematické kolekce

Národní archiv - veřejnoprávní původci

archivace specifických zdrojů

Ústav pro českou literaturu AV ČR

výzkumné projekty

Vývoj centralizovaného rozhraní pro vytěžování velkých dat z webových archivů

Národní archiv - veřejnoprávní původci

Klíčová slova sklizně: státní správa, Národní archiv, veřejná správa, ministerstva



Národní archiv ze zákona vykonává dohled nad vyřazováním dokumentů a kontrolu spisové služby u řady orgánů a organizací. Tematická kolekce zahrnuje webové stránky veřejnoprávních původců, o jejichž tzv. předarchivní péči se stará Patří k nim zákonem určená ministerstva, ústřední správní úřady, právnické osoby zřízené zákonem a organizační složky státu s celostátní působností včetně jimi zřízených příspěvkových organizací a také vrcholné instituce justice.

Agentura ochrany přírody a krajiny ČR

www.ochranaprirody.cz [archivovaná verze]

Antidopingový výbor ČR

antidoping.cz [archivovaná verze]

<u>Asociace neprofesionálních komorních a</u> <u>symfonických těles : ANKST</u>

ankst.cz [archivovaná verze]

Celní správa České republiky

www.cs.mfcr.cz/cmsgrc/ [archivovaná verze]

CENIA: česká informační agentura životního

Budoucnost

Webový archiv není jen skladiště URL, na které usedá prach. Pracujeme na vytvoření fulltextu celého archivu. Potřebujeme porozumět tomu, co nesou jednotlivé digitální objekty a co budou znamenat historicky.

Čeká nás otevření Webarchivu analytickému výzkumu a propojení našich dat s jinými archivy.



Děkuji za pozornost

Marie Haškovcová

www.webarchiv.cz

www.facebook.com/webarchivcz

marie.haskovcova@nkp.cz

 $\underline{\mathbf{W}}$

W W

 $\underline{\mathbf{W}} \ \underline{\mathbf{W}} \ \underline{\mathbf{W}}$